# ANALYSE DU PROFIL SOCIODÉMOGRAPHIQUE DES ÉTUDIANTS DATA

# OBJECTIF DE L'ÉTUDE

Décrire le profil des étudiants Data

Analyser leur répartition socio-démographique

Mesurer leur évolution dans le temps

Comparaison avec les populations régionales

# ORIGINE DES DONNEES

**Données OpenClassrooms :**

- Parcours
- Tranche d'âge
- Région
- Genre
- Date de début de parcours

**Données INSEE :**

- Tranches d'âge par région
- Population par région
- Part des genres par région

# MÉTHODOLOGIE

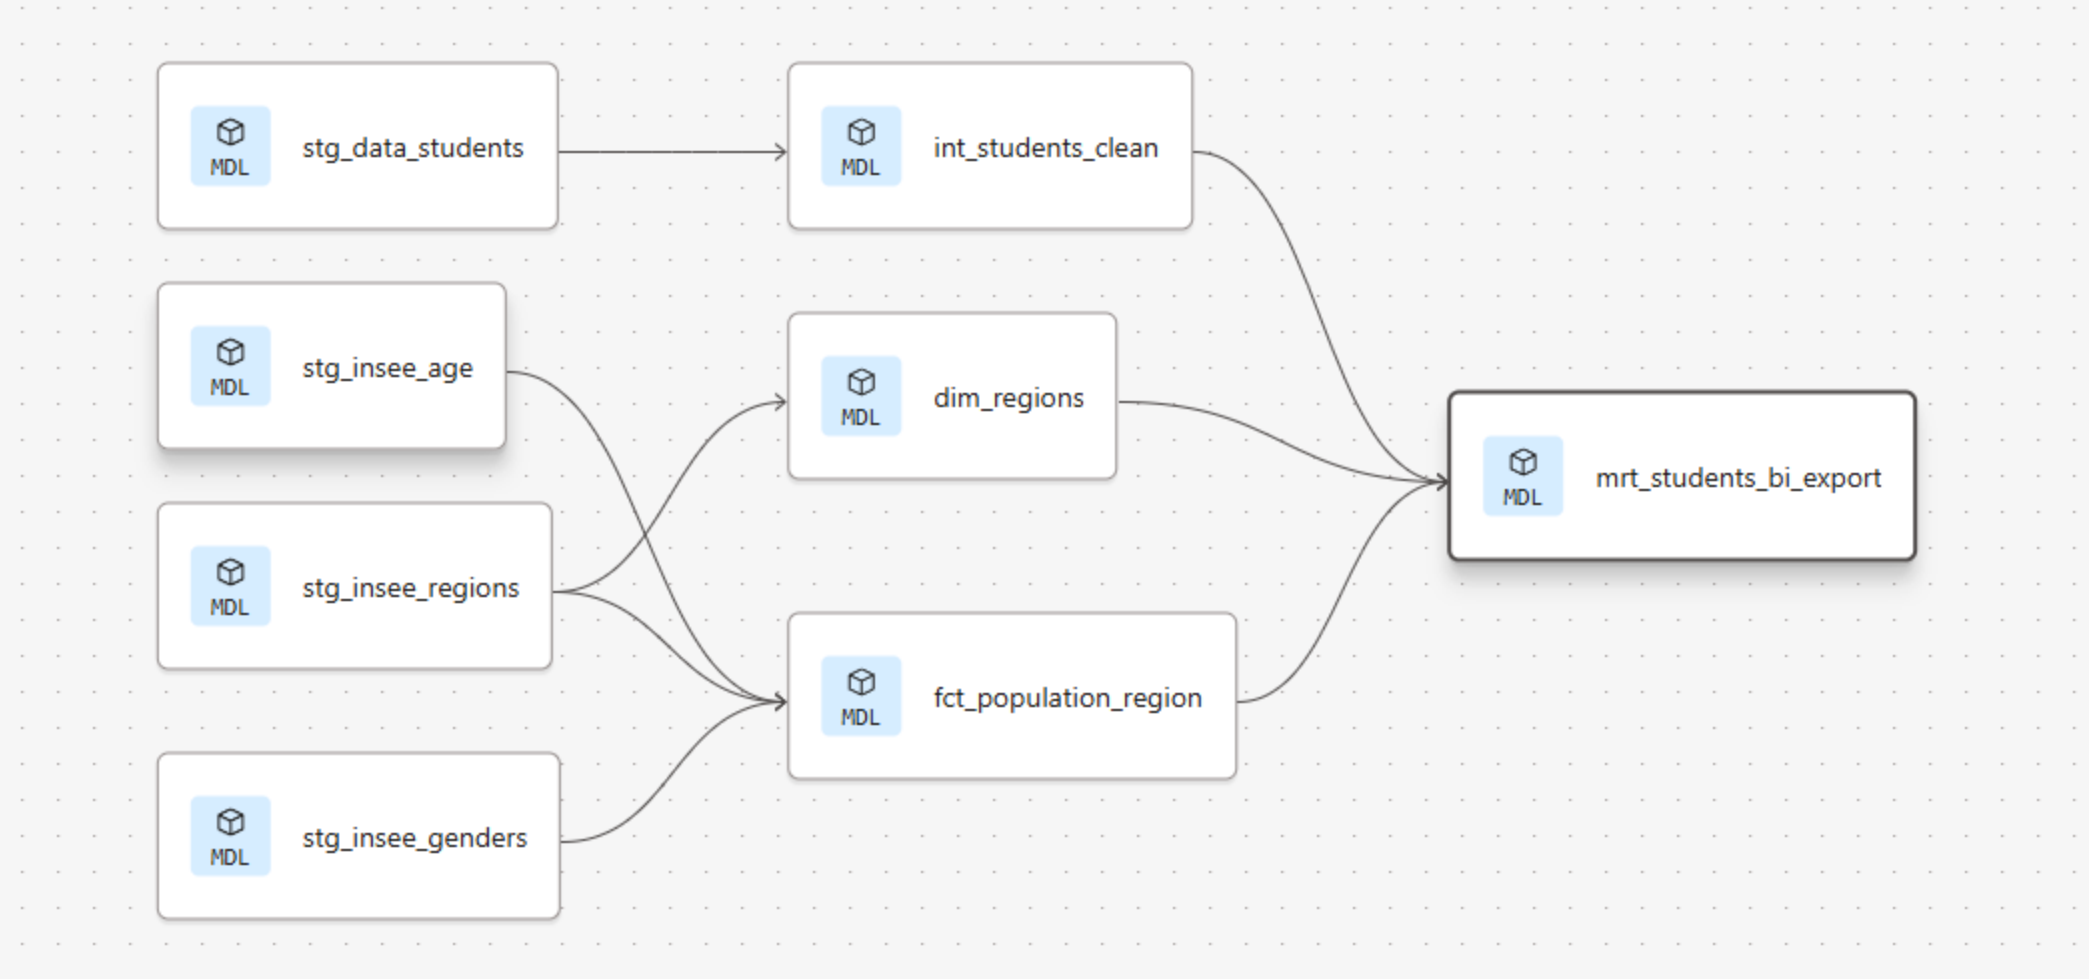
**DBT Cloud :**

- Fichiers sources
- Partie Staging (nettoyage, standardisation)
- Partie Intermediate (préparation données, agrégations, etc.)
- Partie Marts (données prêtes à être analysées)
- Fichier final pour POWER BI

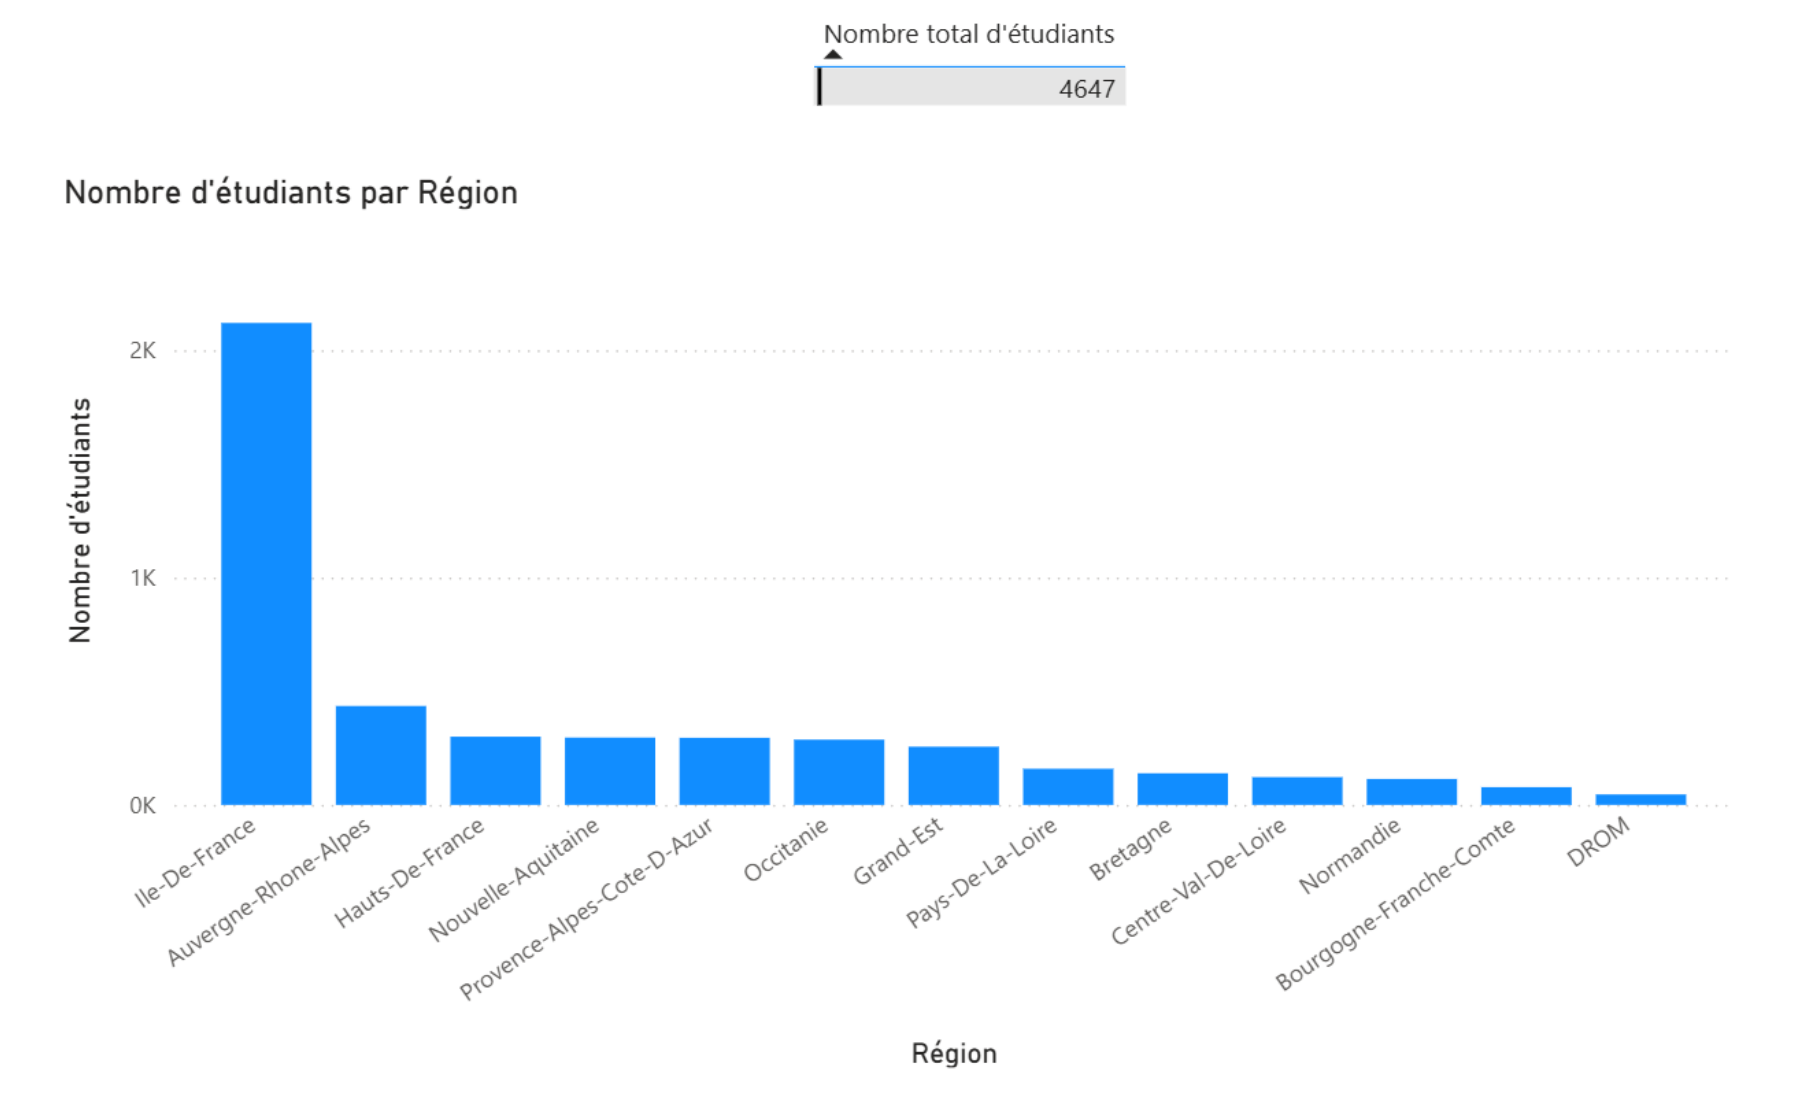
**Snowflake :**

- Centralisation des données sources
- Stockage des données
- Exécution des transformations SQL

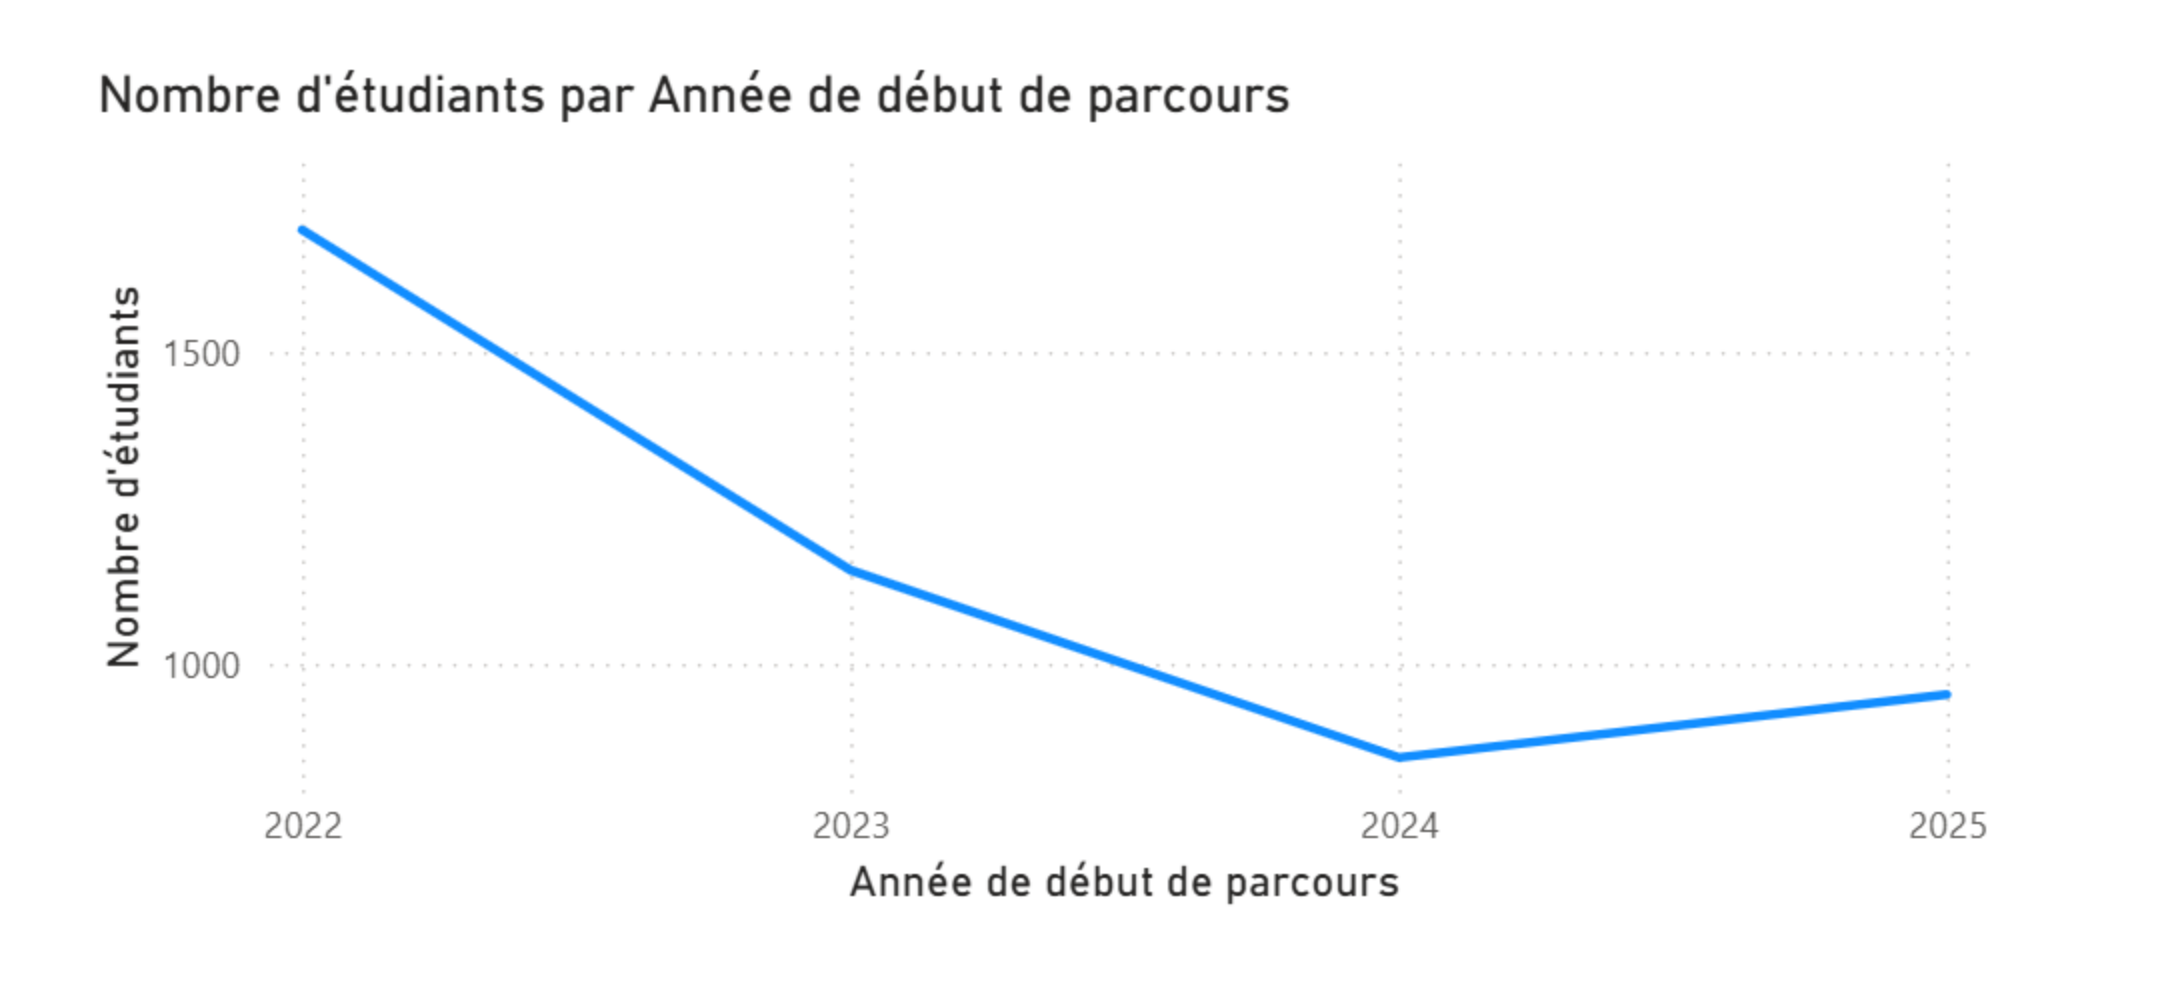
# LINEAGE DBT CLOUD



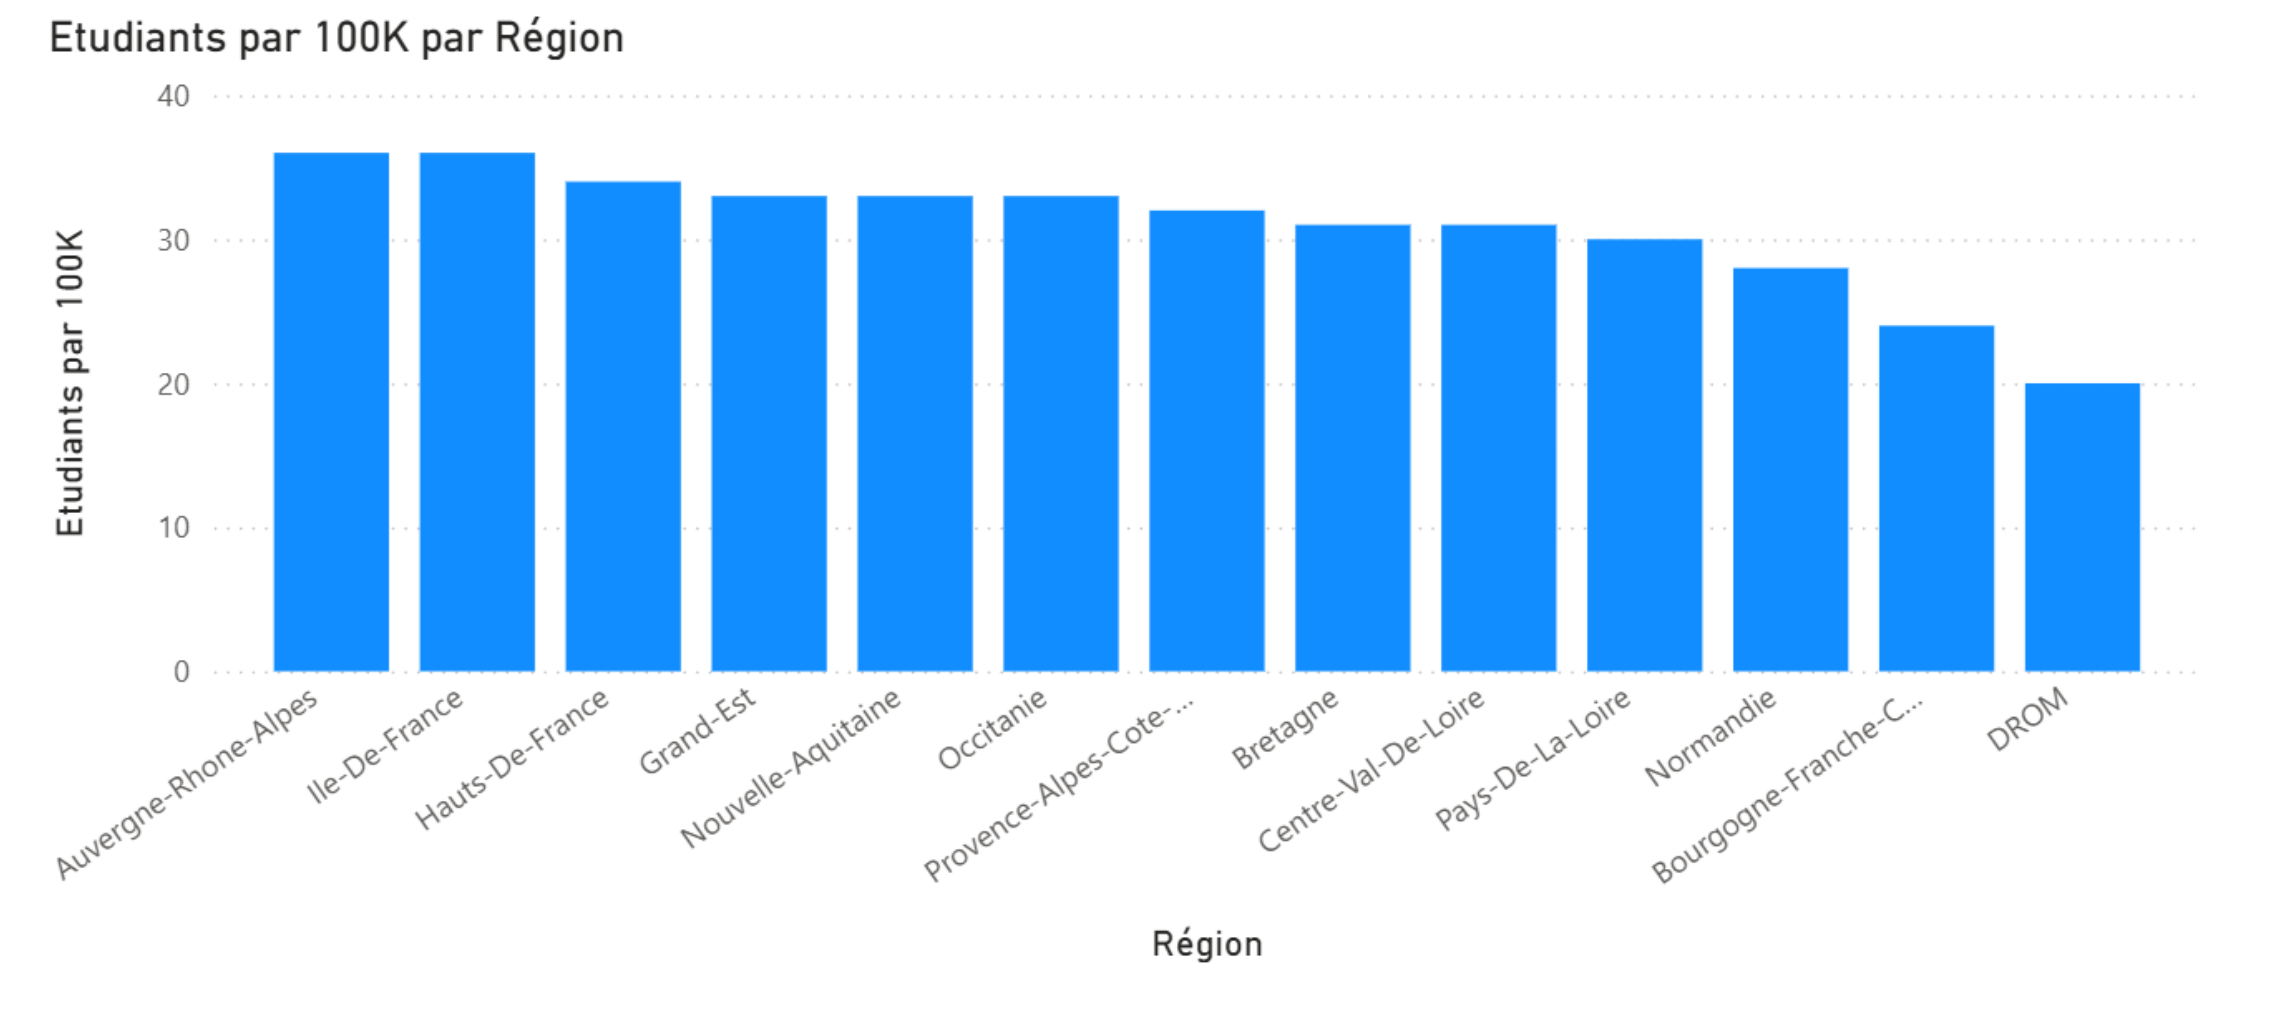
# PRÉSENTATION GÉNÉRALE



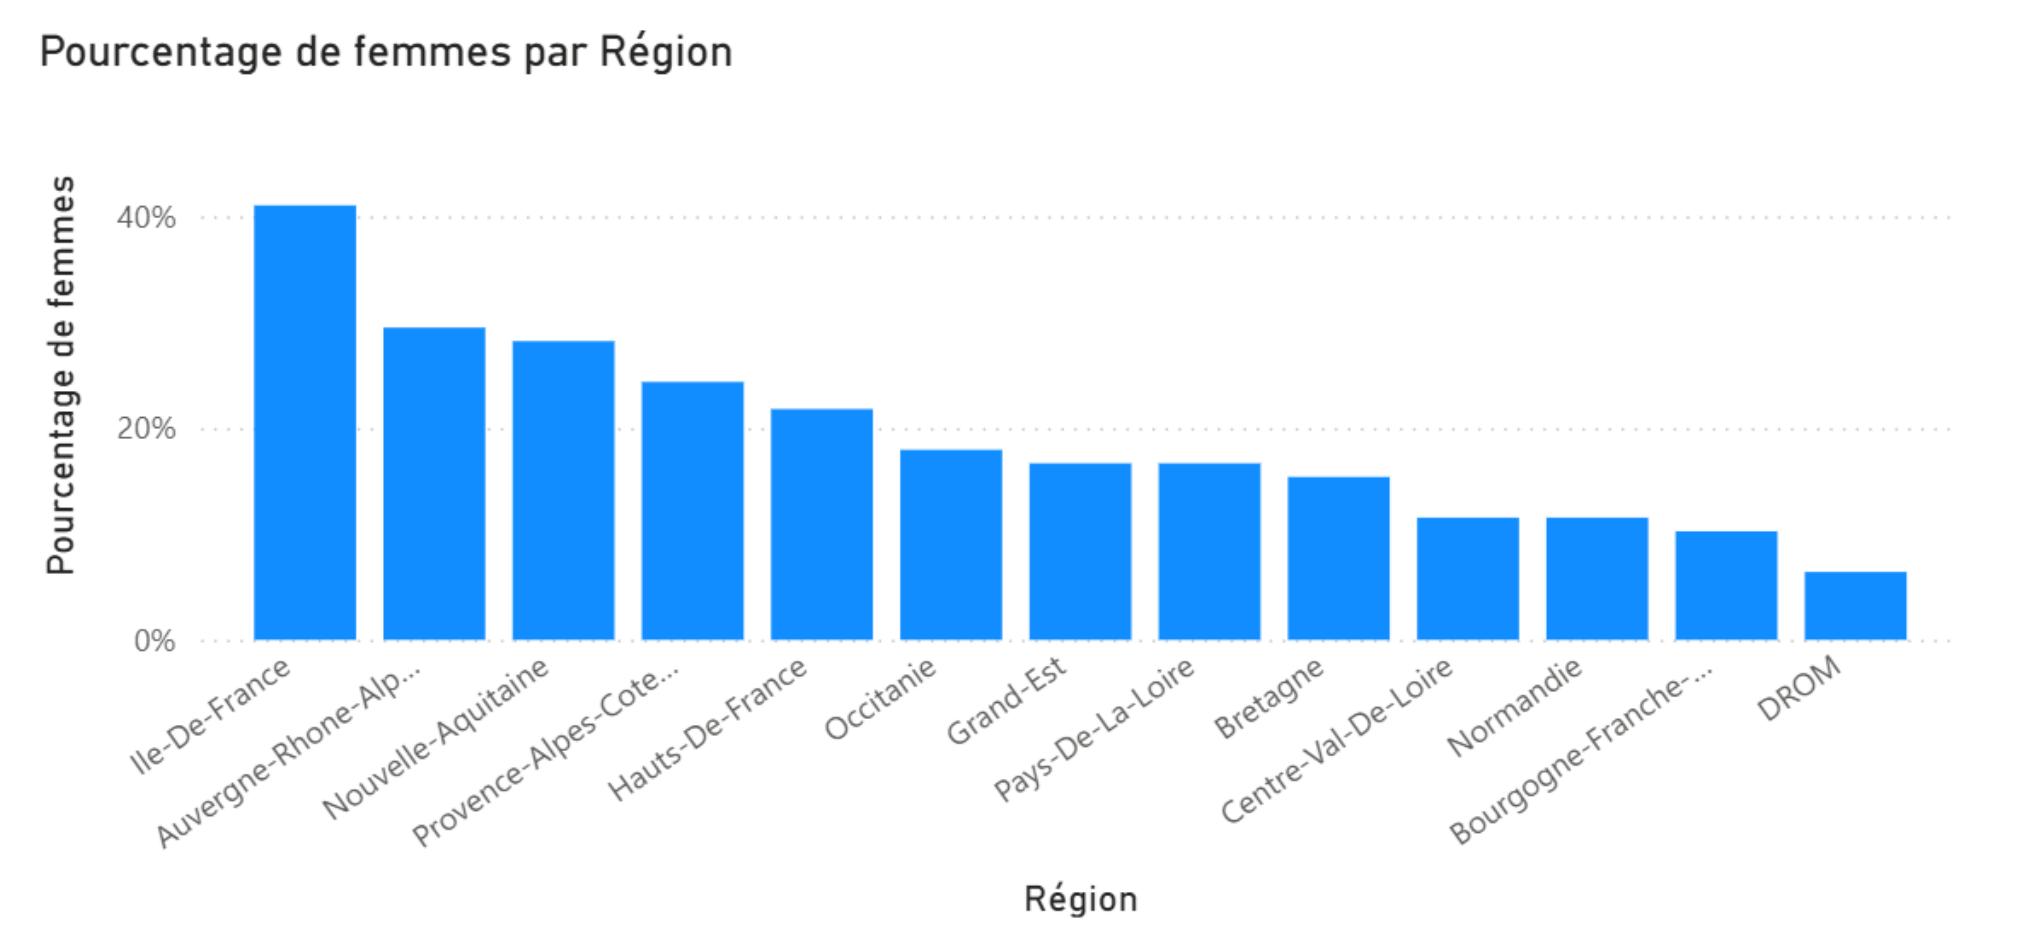
# ÉVOLUTION DU NOMBRE D'ÉTUDIANTS



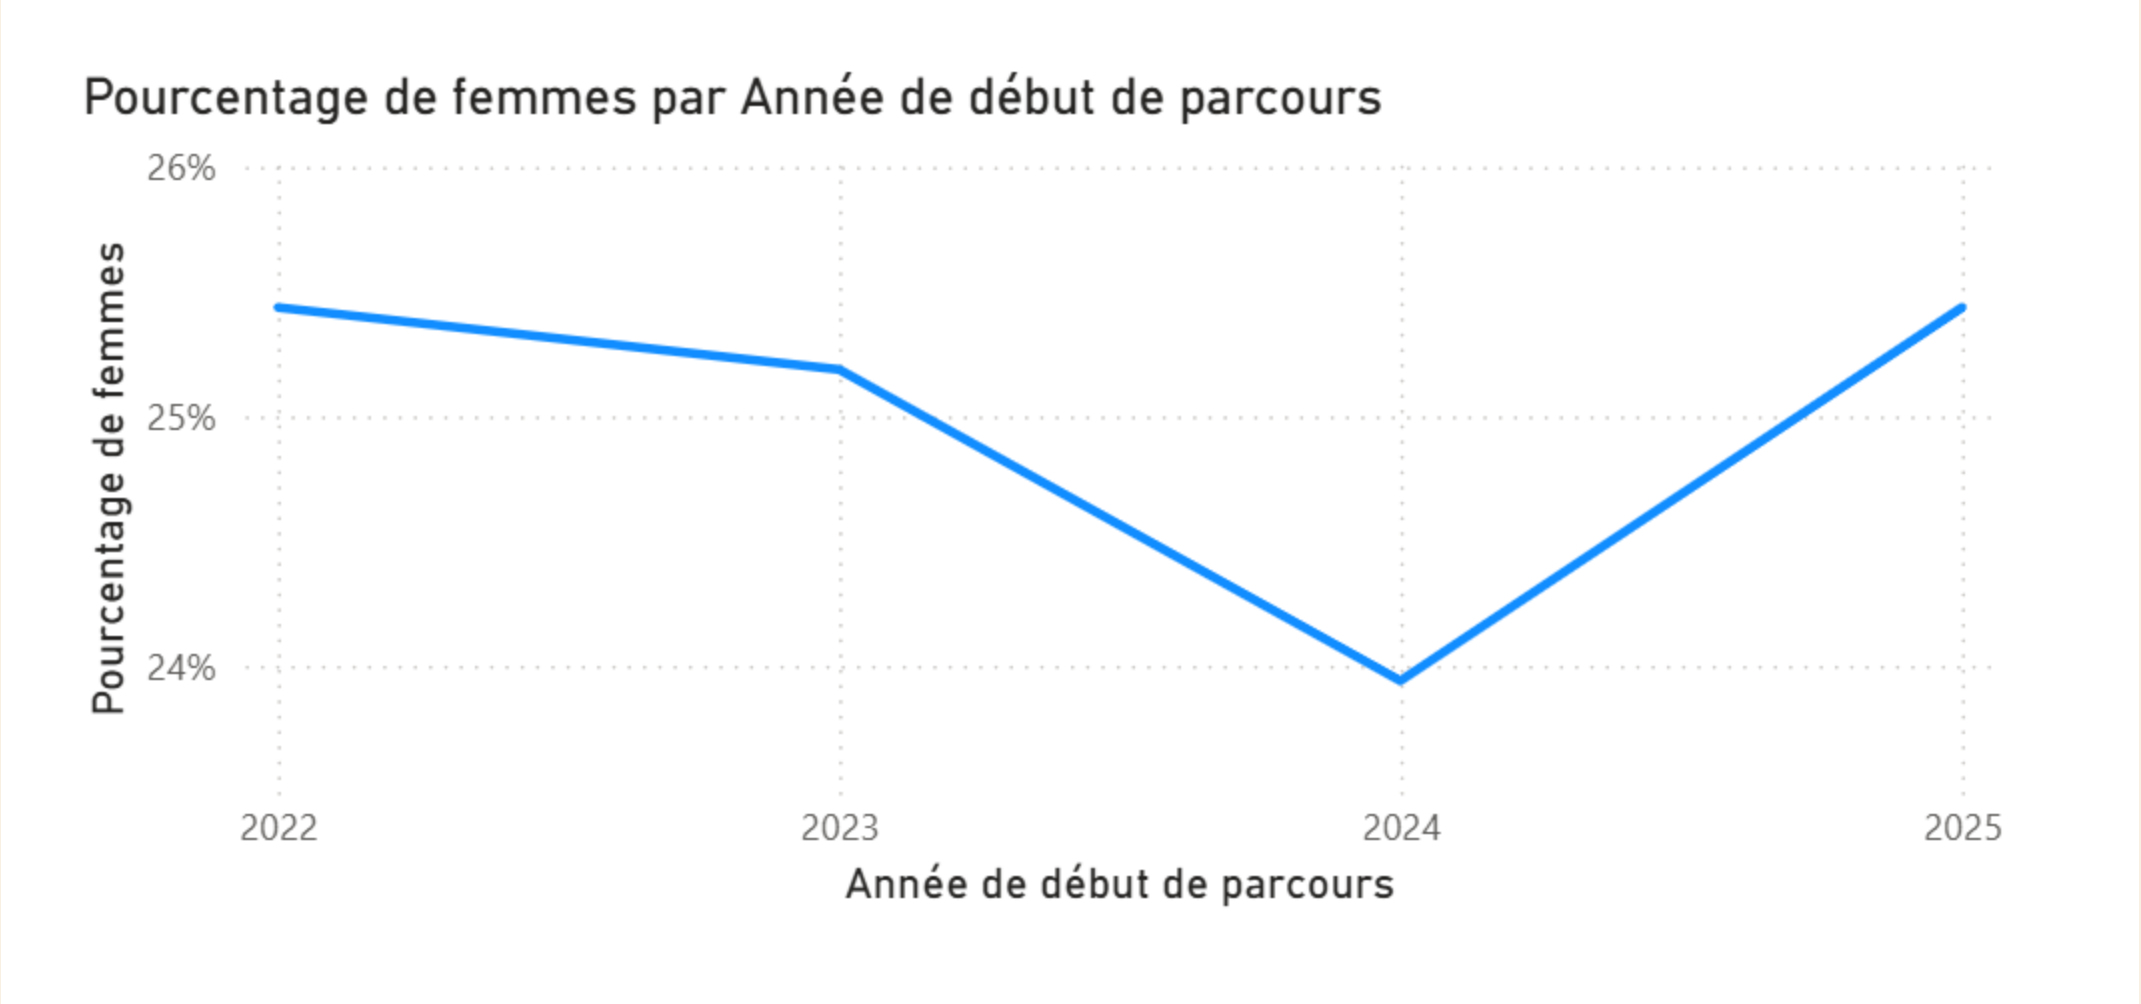
# ATTRACTIVITÉ RÉGIONALE



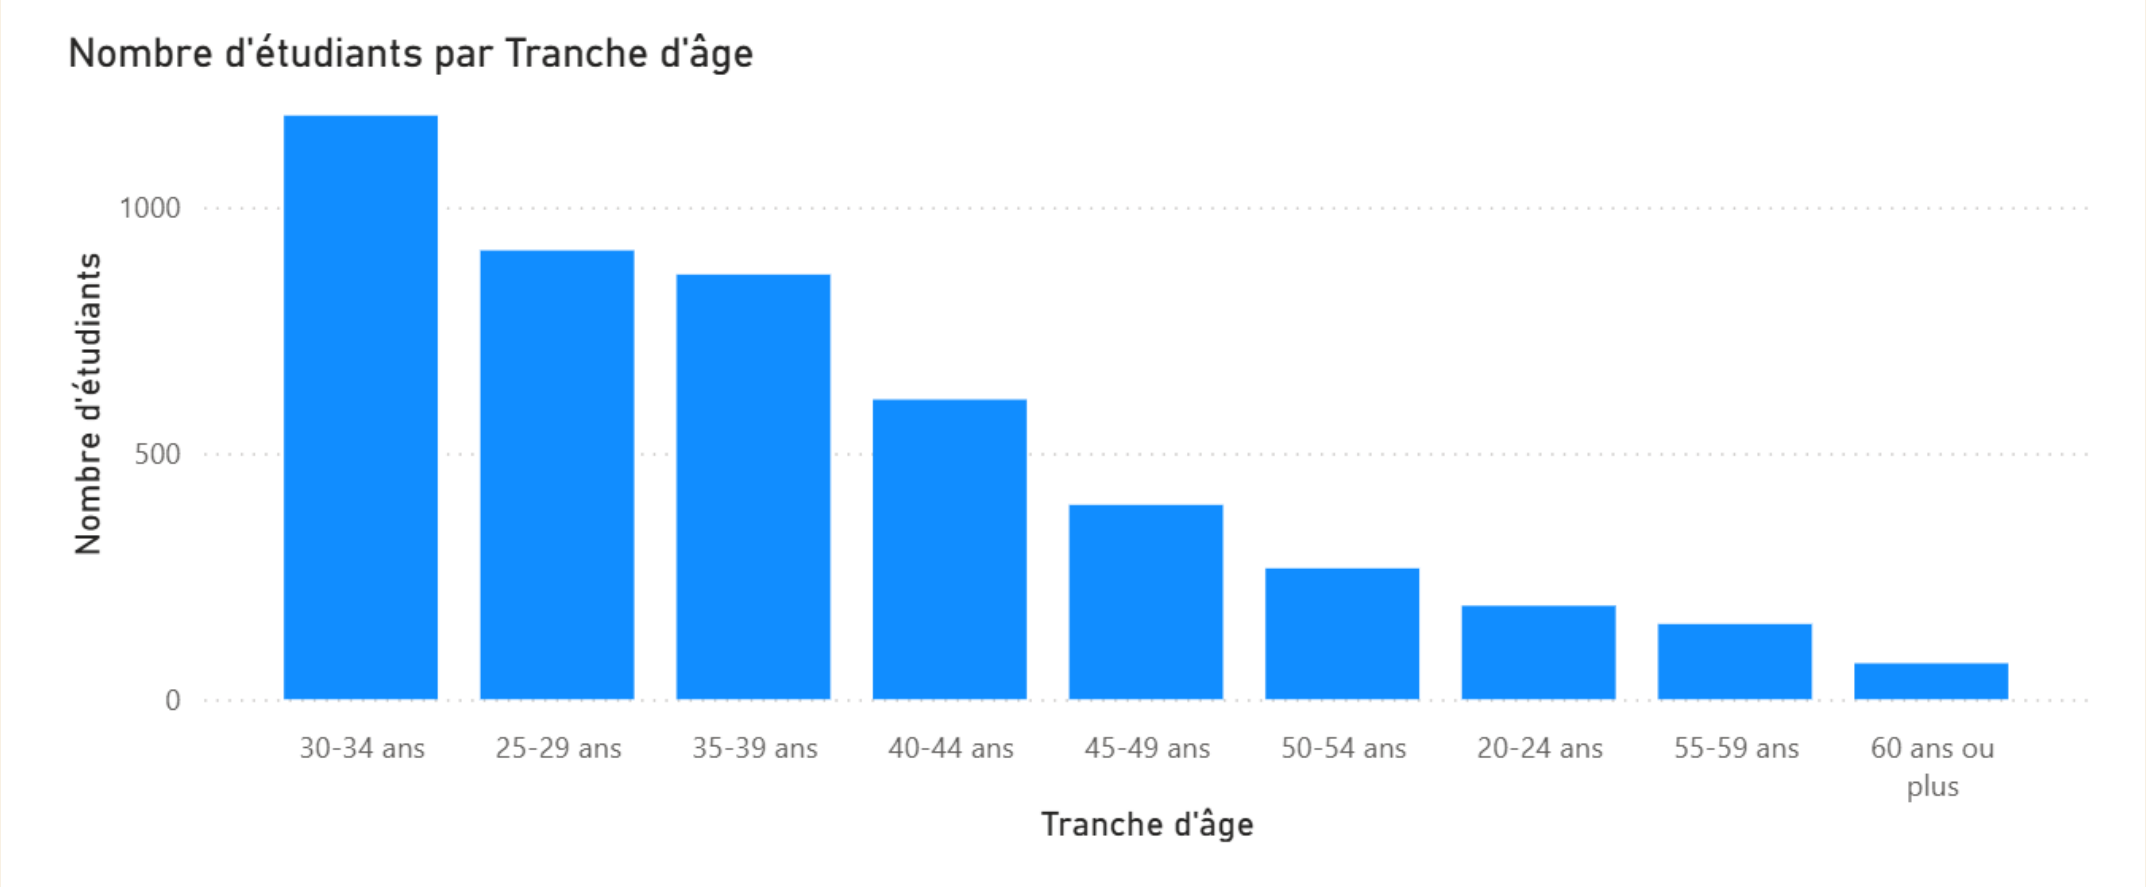
# GENRE DES ÉTUDIANTS



# GENRE DES ÉTUDIANTS



# RÉPARTITION PAR ÂGE



# ÂGE ET RÉGION

| Région | 20-24 ans | 25-29 ans | 30-34 ans | 35-39 ans | 40-44 ans | 45-49 ans | 50-54 ans | 55-59 ans | 60 ans ou plus | **Total** |
|---|---|---|---|---|---|---|---|---|---|---|
| Auvergne-Rhone-Alpes | 26 | 92 | 105 | 68 | 67 | 37 | 20 | 11 | 9 | **435** |
| Bourgogne-Franche-Comte | 9 | 16 | 26 | 11 | 4 | 6 | 3 | 3 | | **78** |
| Bretagne | 8 | 25 | 37 | 19 | 21 | 17 | 5 | 3 | 4 | **139** |
| Centre-Val-De-Loire | 6 | 26 | 27 | 29 | 15 | 9 | 4 | 2 | 4 | **122** |
| DROM | 1 | 4 | 11 | 7 | 11 | 8 | 3 | | 1 | **46** |
| Grand-Est | 13 | 50 | 61 | 59 | 27 | 19 | 14 | 12 | 1 | **256** |
| Hauts-De-France | 18 | 50 | 80 | 58 | 34 | 22 | 26 | 9 | 3 | **300** |
| Ile-De-France | 67 | 432 | 529 | 416 | 279 | 171 | 118 | 69 | 39 | **2120** |
| Normandie | 4 | 19 | 28 | 24 | 17 | 9 | 11 | 2 | | **114** |
| Nouvelle-Aquitaine | 15 | 57 | 72 | 44 | 40 | 30 | 25 | 9 | 4 | **296** |
| Occitanie | 13 | 57 | 83 | 49 | 38 | 22 | 9 | 13 | 3 | **287** |
| Pays-De-La-Loire | 2 | 29 | 41 | 29 | 17 | 20 | 12 | 9 | | **159** |
| Provence-Alpes-Cote-D-Azur | 8 | 55 | 86 | 50 | 39 | 25 | 16 | 11 | 5 | **295** |
| **Total** | **190** | **912** | **1186** | **863** | **609** | **395** | **266** | **153** | **73** | **4647** |

# ANALYSE DES RÉSULTATS

- Les étudiants présentent des caractéristiques sociodémographiques relativement marquées en termes d'âge (25-39 ans) et de répartition géographique (IDF).
- Les données nous apprennent que les régions sont plutôt également attractives rapportées à leur population (sauf DROM et régions les moins urbanisées).
- La part des femmes est la plus élevée dans les régions les plus urbanisées.
- La part des femmes reste stable par année de parcours.
- Le parcours Data voit sa popularité baisser ces dernières années en terme de nombre d'étudiants.

# CONCLUSION

Mise en œuvre d'une chaîne décisionnelle complète grâce à :

- Snowflake pour le stockage des données et l'exécution des fichiers SQL,
- DBT Cloud pour la transformation des données prêtes à être utilisées pour l'analyse,
- Power BI pour l'analyse des données et la visualisation.

# MERCI

Gabriel CAPELL

capell.gabriel@gmail.com